

성남시 109번 마을버스 도착 예정 시간 예측 (DNN 기반 회 귀 모델)

공공 데이터와 딥러닝(Swish)을 활용한 도착 오차 개선 연구

소속: 백석대학교 컴퓨터공학부 소프트웨어학과

발표자: 20213803 허준호



Slide 2: 목차

01

연구 배경 및 목적

(Introduction)

02

도로 데이터 분석

(Data Analysis)

03

제안 모델 및 아이디어

(Proposed Method)

04

활성화 함수 비교

(Swish vs ReLU)

05

실험 및 결과

(Experiments & Results)

06

결론 및 한계점

(Conclusion)

Slide 3: 연구 배경 - 왜 마을버스인가?

1. 문제 정의


- 버스 정류장 단말기(BIT)와 모바일 앱 간의 도착 시간 불일치 발생
- 기존 예측 방식은 교통 변수에 민감한 마을버스의 도착 시간을 정확히 예측하기 어려움

2. 연구 목표

- 고가의 GNSS 장비 없이, 접근 가능한 **공공 데이터(교통량, 날씨 등)** 활용
- **DNN(Deep Neural Network) 기반 회귀 모델**을 통해 비선형적 교통 패턴 학습

Slide 4: 데이터 수집 및 분석


1. 데이터 한계 및 극복



```
project > rust_project > road_traffic_collector > src > main.rs > main
11 use std::time::Duration;
12 use std::sync::Arc;
13 use tokio::sync::Mutex;
14
15 #[tokio::main]
16 async fn main() {
17     let client = reqwest::Client::new();
18     let file_lock = Arc::new(Mutex::new(()));
19
20     let mut scheduler = AsyncScheduler::with_timezone(Asia_
21 );
22
23     scheduler.every(10.minutes()).run(move || {
24         let client_clone = client.clone();
25         let lock_clone = file_lock.clone();
26
27         async move {
28             let now_seoul = Utc::now().with_timezone(G7Z::
29 );
30             let current_hour = now_seoul.hour();
31
32             if current_hour >= 6 && current_hour < 23 {
33                 println!("🟢 현재 시간({})은 교통량 수집합니다. ",
34 );
35                 if let Err(e) = sender::send_requests(client_
36 ); {
37                     eprintln!("❌ 교통량 수집에 실패했습니다: {}",
38 );
39                 }
40             } else {
41                 println!("🟡 현재 시간({})은 교통량 수집하지 않습니다. ",
42 );
43             }
44         }
45     });
46
47     loop {
48         scheduler.run_pending().await;
49         tokio::time::sleep(Duration::from_millis(500)).awa
50     }
51 }
```

- 기존 T-Map 및 공공 데이터 API: 마을 안쪽 도로 정보 부재 및 실제 상황과 불일치
- **해결책:** 도로교통정보센터 API를 활용, 개인 서버로 1개월간 10분 간격 데이터 직접 수집


2. 교통량 분석 결과



- **평일:** 출근(0809시), 퇴근(1719시) 시간대 정체 뚜렷
- **주말:** 특정 피크 타임 없이 정오 기준 고르게 분포


Slide 5: 제안 모델 (Proposed Model)

1. 모델 구조



- **입력 변수**: 요일, 시간, 날씨, 도로 교통량 등
- **출력 변수**: 버스 도착 소요 시간 (회귀 분석)


2. 학습 최적화 기법



- **과적합(Overfitting) 방지**: Batch Normalization과 Dropout 기법 동시 적용
- 실험 결과 두 기법을 혼용했을 때 오차가 가장 최소화됨


Slide 6: 핵심 아이디어 - Swish 활성화 함수

1. 기존 ReLU의 한계



- 입력값이 음수일 경우 0을 출력하여 뉴런이 죽는 '**Dying ReLU**' 현상 발생


2. Swish 함수 도입




- 음수 영역에서도 0이 아닌 값을 출력하여 정보 손실 방지
- 복잡한 도로 데이터 패턴 학습에 더 유연하게 대처 가능

Slide 7: 실험 결과 (Quantitative Results)

1. 학습 결과




- 평균 오차: 약 402초 (약 6.5분)
- 랜덤 샘플 테스트 결과, 예측값이 실제값과 상당한 차이를 보임




2. 원인 분석


- 공공 데이터 자체의 정밀도 한계 및 다량의 노이즈(Noise) 존재
- 날씨 변수(강수량 등)가 겨울철 데이터 부족으로 영향력이 미미했음



Accracy 3/50



Accracy 1/50(Dying)



Accracy 5/50

Slide 8: 활성화 함수별 성능 비교

Sigmoid

MinMax Scaling 영향으로 의외로 높은 정확도 기록

ReLU

학습 초반 큰 기울기로 인해 'Dying ReLU' 현상 발생, 학습 중단

Swish

Sigmoid와 ReLU의 중간 정도 민감도를 보이며 그래프 경향성 반영

Slide 9: 결론 및 향후 과제

1. 결론

- 간접적인 도로 데이터(공공 데이터)만으로는 정밀한 버스 예측에 한계가 있음
- 단순 데이터 학습량 증가는 모델 성능 향상으로 이어지지 않음 (Plateau 현상)

2. 향후 연구 방향

- **고정밀 데이터 필요:** 버스에 직접 부착된 GNSS 등의 실시간 위치 데이터 활용 필수
- **데이터 정제:** 노이즈를 제거하고 더욱 정밀한 도로 구조 가중치 적용 필요

Slide 10: 참고 문헌

- 이진우 외, "Levenberg-Marquardt 알고리즘을 이용한 시내버스 지연요소 추정", 한국전자통신학회 논문지 (2017)
- 한국ITS학회, "Markov Chain을 이용한 버스지체시간 예측 (The Bus Delay Time Prediction Using Markov Chain)", 한국ITS학회 논문지, 8(3), 1-10, (2009)
- Ramachandran et al., "Swish: a Self-Gated Activation Function", arXiv (2017)

감사합니다.